

Atelier ACE : Génétique des maladies rares et tests de charge génétique.

Presented by: Joanne Berghout, PhD

Spécialiste en génomique computationnelle humaine, Division de bio-informatique et de biologie computationnelle, National Institute of Allergy and Infectious Disease (NIAID), National Institutes of Health (NIH), Bethesda, MD, USA

Variation génétique et maladie

- Chaque génome humain compte environ 6 milliards de nucleotides
- Les génomes humains sont identiques à 99,6 % entre eux ; cependant:
 - chaque personne porte environ 5 millions de VNS (variants nucléotidiques simples), ainsi que d'autres types de variation (insertions et délétions, répétitions en tandem, variation structurale)
- La grande majorité de cette variation est neutre sur le plan phénotypique et clinique – elle n'a aucun effet
- Une autre grande partie est commune et a un effet très faible sur les traits de santé humaine
- Certains exemples de variation rare peuvent être catastrophiques et provoquer des maladies et syndromes génétiques rares

Une composante fondamentale de la recherche axée sur les maladies consiste à distinguer les variants pertinents des variants non liés au trait d'intérêt



Maladie génétique rare


1. Un **gène** donné est-il causalement associé à une maladie ?
2. Un **variant** donné affectant ce gène est-il associé à la maladie ?



Définitions:

- **Gène** : l'unité fonctionnelle de base codée dans l'ADN et exprimée en un produit moléculaire discret (ARNm, protéine)
- **Allèle/variant** : l'une des deux versions possibles (ou plus) d'une séquence d'ADN à un emplacement génomique donné (p. ex. chr1:55039995-C). Peut parfois désigner la position elle-même, avec ou sans détails sur la variation connue dans la population humaine (p. ex. chr1:55039995-C/T, rs334)
- **Diploïde** : la présence de deux ensembles complets de chromosomes dans les cellules d'un organisme, un ensemble hérité de chaque gamète parental. Les humains sont diploïdes.
- **Génotype** : la paire diploïde d'allèles qu'un individu donné porte à un emplacement génomique particulier (p. ex. AA, AG, GG, CT, ...). Les génotypes peuvent être homozygotes (identiques entre eux) ou hétérozygotes (différents entre eux) chez une personne.
- **Génome de référence** : une représentation acceptée de la séquence du génome humain (contrôlée par version ; GRCh38 est courante) utilisée par les chercheurs comme norme de comparaison avec les séquences d'ADN générées dans leurs études. Le génome de référence n'est pas un idéal humain « parfait et en bonne santé » ; puisqu'il est concrètement ACTG à tous les loci, il contient des allèles pouvant être associés à un risque accru et/ou diminué de maladies courantes, ainsi que des versions de gènes pouvant prédire certains traits. Le génome de référence n'est pas une personne réelle.



Principes d'association des maladies génétiques rares




1. Le variant causal doit être rare
2. Le variant causal doit être plus fréquent chez les cas atteints que chez les témoins non atteints
 - Si des données génétiques familiales sont disponibles, le variant causal doit ségréger avec le trait dans cette famille
3. Le variant doit avoir un effet fonctionnel sur la biologie différent de la référence
 1. Prédiction bio-informatiques, tests expérimentaux
4. Une deuxième ligne de preuve indépendante soutient également la relation gène-maladie
 1. Autres familles ou études, modèles animaux

Principes d'association des maladies génétiques rares

- **Hétérogénéité génétique** : lorsque des mutations dans un certain nombre de gènes différents peuvent toutes provoquer le même diagnostic clinique



- **Hétérogénéité allélique** : lorsque des personnes ayant le même diagnostic clinique et le même gène causal présentent des allèles pathogènes différents



Fondement conceptuel
des tests de charge


Tests de charge (burden) et SKAT (test d'association par noyau de sequence) pour l'association gène-maladie

- *Suppose une hétérogénéité allélique* et utilise le gène – plutôt que le variant – comme unité d'association
- **Test de charge** (burden test) : regroupe tous les variants qualifiants au niveau du gène avant le test d'association
- **SKAT**: utilise une statistique de composante de variance (pondérée par la fréquence inverse) qui crée un score de similarité patient à patient pour le gène. Autrement dit, si deux patients portent tous deux un variant ultra-rare au sein d'un gène, ils sont mathématiquement évalués comme deux individus très similaires.
- **SKAT-o (SKAT-optimal)**: combine burden + SKAT

Comparaison de modèles statistiques

Caractéristique	Burden Test (plus intuitif)	SKAT tests (plus sophistiqués)
Mécanisme central	Regroupe/agrège les variants en un score génétique unique avant de tester l'association	Agrège les statistiques de test des variants individuels en utilisant la similarité génotypique par paire
La direction de l'effet		
Variants non causaux		
Scénario optimal		
Cadre statistique		
Paramètre de non-centralité		

Principes d'association des maladies génétiques rares



1. Le variant causal doit être rare
2. Le variant causal doit être plus fréquent chez les cas atteints que chez les témoins non atteints
 - Si des données génétiques familiales sont disponibles, le variant causal doit ségréger avec le trait dans cette famille
3. Le variant doit avoir un effet fonctionnel sur la biologie différent de la référence
 1. Prédiction bio-informatique, tests expérimentaux
4. Une deuxième ligne de preuve indépendante soutient également la relation gène-maladie
 1. Autres familles ou études, modèles animaux

Annotation des variants : comment savoir si un variant est rare

- Commencez par votre maladie/trait, pas par la génétique
- Si la maladie est bien étudiée, consultez les études de cohorte connues et les variants pathogènes déjà rapportés comme guide
 - ClinVar : <https://www.ncbi.nlm.nih.gov/clinvar/>
 - Votre propre cohorte
- Exploitez les grandes ressources publiques
 - gnomAD (see also GenIE): <https://gnomad.broadinstitute.org/> (<https://gnomad.broadinstitute.org/news/2024-06-genie/>)
 - All of Us: <https://databrowser.researchallofus.org/snvsindels/>
- Portez attention à l'ascendance
 - De nombreux variants peuvent être rares dans une population, mais observés plus fréquemment dans une autre
- La fréquence est le critère le plus important pour « qualifier » un variant

Annotation des variants : comment savoir si un variant est rare

- Équilibre de Hardy-Weinberg où :
 - p = fréquence de l'allèle majeur
 - q = fréquence de l'allèle mineur

$$1 = p^2 + 2pq + q^2$$

En supposant que la fréquence de l'allèle mineur = 0,01, les fréquences génotypiques deviennent :


$$1 = (1 - 0.01)^2 + 2(1 - 0.01)(0.01) + (0.01)^2$$

98.01%

1.98%

0.01%

1 personne sur 10 000
sera homozygote



ClinVar: <https://www.ncbi.nlm.nih.gov/clinvar/>

- Une base de données de variants rares, fournis par des soumetteurs, interprétés par des généticiens cliniciens quant à leur potentiel à causer une maladie
 - Sociétés professionnelles et accréditées de tests génétiques cliniques
 - Chercheurs du domaine
 - Conçue comme un moyen de partager des informations sur les variants avec l'ensemble du domaine
- Observationnelle, avec des variants observés chez de vraies personnes ayant subi des tests génétiques cliniques ou participé à des études de recherche en génétique clinique
- Classée selon les catégories d'interprétation ACMG
 - **Pathogène** : cause une maladie génétique
 - **Probablement pathogène** : censé causer une maladie, mais certaines preuves convaincantes manquent
 - **Variant de signification incertaine** : répond à certains critères mais aucune décision n'a pu être prise
 - **Probablement bénin** : pensé ne pas causer de maladie, mais certaines preuves convaincantes manquent
 - **Bénin** : ne cause pas de maladie génétique

Ressource ClinVar: page de variant

NM_007294.4(BRCA1):c.5191G>T (p.Glu1731Ter)

Classification: Pathogenic (4), Likely pathogenic (1)

No data submitted for somatic clinical impact

No data submitted for oncogenicity

Variant Details

Identifiers: NM_007294.4(BRCA1):c.5191G>T (p.Glu1731Ter)

Type and length: single nucleotide variant, 1 bp

Location: cytogenetic: 17q21.31 - 17:43063335 (GRCh38) [NCBI UCSC] 17:41215952 (GRCh37) [NCBI UCSC]

Timeline in ClinVar:

First in ClinVar	Last submission	Last evaluated
Germline	Jan 1, 2018	Jun 24, 2025

HGVS:

Nucleotide	Protein	Molecular consequence
NM_007294.4:c.5191G>T	NP_059225.1:p.Glu1731Ter	nononsense
NM_001401791.1:c.4519G>T	NP_001394555.1:p.Glu1440Ter	nononsense
NM_001401781.1:c.5257G>T	NP_001394519.1:p.Glu1737Ter	nononsense

Protein change: E1731* E524* E1732* E1644* E1439* E1618* E1642* E1600* E519* E548* E546* E588* E561* E539* E584* E524* E530* E585* E1644* E1602* E1603* E1619* E1641* E1640* E1645* E1689* E1689* E1720* E1700* E1700* E1722* E451* E500* E501* E519* E581* E581* E586* E587* E587* E582* E1604* E1620* E1642* E1661* E1728* E1728* E1729* E1730* E514* E516* E538* E540* E550* E580* E581* E582* E582* E520* E520* E1707* E1547* E1640* E1640* E1645* E1689* E1711* E1712* E1720* E1751* E1751* E1753* E400* E515* E539* E540* E560* E580* E580* E583*

Other names: NC_000017.11:43063334.C.A

Global minor allele frequency (GMAF): -

Allele frequency: -

Links: ClinGen: CA10591159, dbSNP: rs397507244, VePScore: -

Genes:

Gene	OMIM	ClinGen Gene Dosage Sensitivity Curation		Variation Viewer	Related variants	
		HS score	TS score		Within gene	All
BRCA1	113787	Sufficient evidence for dosage pathogenicity	No evidence available	GRCh38 (GRCh37)	14044	16062

Conditions - Germline:


Condition	Classification (# of submissions)	Review status	Last evaluated	Variation/condition record
Hereditary cancer predisposing syndrome	Pathogenic (2)	★★★★	Jun 24, 2025	RCV005711448.5
Hereditary breast ovarian cancer syndrome	Pathogenic (1)	★★★★	Jun 23, 2023	RCV00698353.8
Breast-ovarian cancer, familial, susceptibility to, 1	Pathogenic/Likely pathogenic (2)	★★★★	Nov 13, 2023	RCV001076151.7

Submissions - Germline:

Classification (Last evaluated)	Review status (Assertion criteria)	Condition	Submitter	Collapse all rows
Likely pathogenic (Aug 05, 2023)	★★★★ (ACMG Guidelines, 2015)	Breast-ovarian cancer, familial, susceptibility to, 1	Baylor Genetics Accession: SCV004215036.1 First in ClinVar: Dec 30, 2023 Last updated: Dec 30, 2023	Observation: 1 • Collection method: clinical testing • Allele origin: unknown • Affected status: unknown
Pathogenic (Nov 13, 2023)	★★★★ (ACMG Guidelines, 2015)	Breast-ovarian cancer, familial, susceptibility to, 1 (Autosomal dominant inheritance)	All of Us Research Program, National Institutes of Health Accession: SCV004839571.1 First in ClinVar: Apr 20, 2024 Last updated: Apr 20, 2024 Comment: This study involves interpretation of variants in research participants for the purpose of population health screening. Participant phenotype was not available at the time of ... (more)	
Pathogenic (Jul 07, 2021)	★★★★ (Ambry Variant Classification Scheme 2023)	Hereditary cancer-predisposing syndrome	Ambry Genetics Accession: SCV000665042.5 First in ClinVar: Jan 01, 2018 Last updated: May 01, 2024	

gnomAD: GeNOMe Aggregation Database



- Environ 800 000 personnes, majoritairement en bonne santé (sans maladie monogénique rare connue)
- Enrichie en ascendance européenne, mais comprend plusieurs milliers d'individus de populations africaines, sud-asiatiques, est-asiatiques, américaines admixées (Amérique du Sud et latino-américaines) et moyen-orientales
 - Assemblée de manière opportuniste à partir de génomes séquencés pour d'autres études génétiques, traitée conjointement et présentée sous forme de statistiques sommaires
- <https://gnomad.broadinstitute.org/>




gnomAD v4.1.1

Search by gene, region, or variant

gnomAD ressource






Annotation des variants : comment savoir si un variant est fonctionnel




Annotation des variants : comment savoir si un variant est fonctionnel // PERTE DE FONCTION

- Les variants avec perte de fonction prédite (pLOF) incluent les délétions, les variants stop-gain, les décalages du cadre de lecture et les perturbations du site d'épissage canonique
- Les variants ayant ces conséquences sont censés empêcher complètement le gène de produire son produit génique fonctionnel
- Ceux-ci sont considérés comme ayant un impact très élevé et seront presque toujours des « variants qualifiés » lorsque vous souhaitez évaluer si une fonction génique perturbée est associée à des résultats biologiques ou cliniques



Annotation des variants : comment savoir si un variant est fonctionnel // SITE D'ÉPISSAGE

- SpliceAI
- Calcule la différence d'affinité et de reconnaissance prédites du spliceosome entre la séquence de référence et la séquence variante ; une grande différence devrait entraîner le variant supplantant la séquence de référence
 - Un variant qui supprime la séquence de référence peut entraîner un saut d'exon, une troncature d'exon, une rétention d'intron, ou l'inclusion d'un pseudoexon
 - Chacun de ces effets est considéré aussi grave qu'un variant pLOF, même s'il n'est pas canonique







Annotation des variants : comment savoir si un variant est fonctionnel // FAUX-SENS


- Les variants faux-sens modifient un acide aminé d'un gène codant pour une protéine
 - Repliement et structure
 - Fonction d'un site actif ou d'une interface de liaison
 - Stabilité de la protéine
 - Capacité pour les modifications post-traductionnelles ou le ciblage correct
- De nombreux variants faux-sens sont compatibles avec une fonction normale et certains sont très courants, mais d'autres variants faux-sens créeront une protéine non fonctionnelle ou instable
- Il existe de nombreux algorithmes bio-informatiques conçus pour prédire la nocivité ou le caractère délétère d'une substitution faux-sens
 - SIFT, PolyPhen, REVEL, PrimateAI, AlphaMissense, VEST4, FATHMM
- En tant que catégorie, celle-ci doit être filtrée en variants prédits délétères et prédits tolérés. Le sous-ensemble prédit délétère sera généralement qualifié pour un test de charge ou une autre étude génotype-phénotype

Annotation des variants : comment savoir si un variant est fonctionnel // SITE D'ÉPISSAGE

- AlphaMissense
- Modèle d'apprentissage profond qui prédit la pathogénicité des variants faux-sens en apprenant des motifs à partir de la séquence protéique, de la structure et de la conservation évolutive entre espèces
- Produit un score qui classe les variants comme probablement bénins, probablement pathogènes, ou incertains, sur la base d'une comparaison entre le variant et l'acide aminé de référence
- De nombreux autres algorithmes existent également



Principes d'association des maladies génétiques rares



1. Le variant causal doit être rare
2. Le variant causal doit être plus fréquent chez les cas atteints que chez les témoins non atteints
 - Si des données génétiques familiales sont disponibles, le variant causal doit ségréger avec le trait dans cette famille
3. Le variant doit avoir un effet fonctionnel sur la biologie différent de la référence
 1. Prédiction bio-informatique, tests expérimentaux
4. Une deuxième ligne de preuve indépendante soutient également la relation gène-maladie
 1. Autres familles ou études, modèles animaux

Flux de travail du test de charge :

1. Utiliser l'expertise du domaine pour définir les paramètres et les covariables clés
2. Annoter tous les variants observés avec leur conséquence, leur fréquence et les prédictions bio-informatiques
3. Appliquer des filtres pour déterminer l'ensemble des variants qualifiés
4. Réaliser une analyse statistique pour déterminer si les cas et les témoins présentent une asymétrie dans leur charge de variants qualifiés porteurs, pour un gène donné

Note: ancestry stratification

- Contrôler la parenté et la stratification au sein de la cohorte prête pour l'analyse est ESSENTIEL pour mener des études génotype-phénotype de manière précise
- Les personnes plus similaires en général seront plus similaires à chaque gène, pas seulement au(x) gène(s) réellement associé(s) à votre trait
 - Cela peut créer des faux positifs (inflation génomique)
- Les maladies peuvent avoir une architecture génétique différente selon les populations, surtout en présence d'effets fondateurs (hétérogénéité génétique ; diapositive 7)
- Meilleure approche : tenir compte de l'ascendance et de toute parenté connue lors du recrutement des cas et des témoins
- Approche suivante recommandée : intégrer les composantes principales comme covariables
 - Pour une cohorte hautement multiethnique, il peut être nécessaire d'aller plus loin et d'utiliser des techniques de méta-analyse